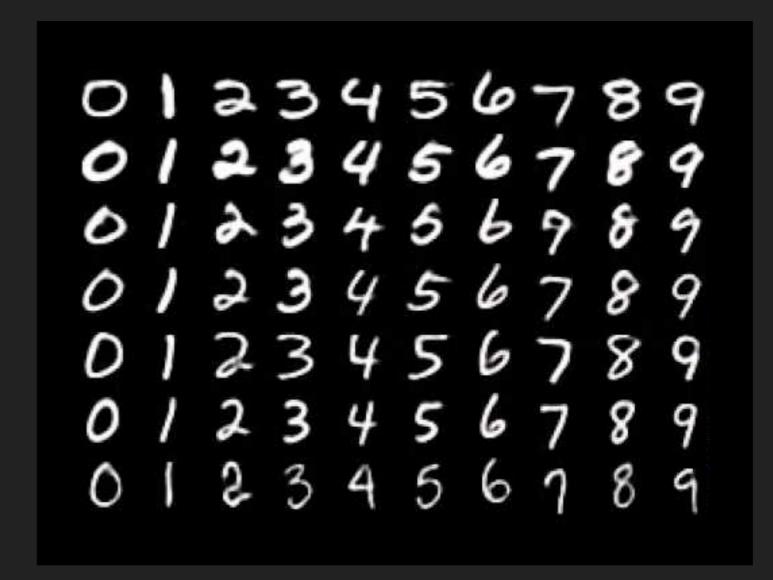
RECONNAISSANCE D'ECRITURE MANUSCRITE

MACHINE LEARNING

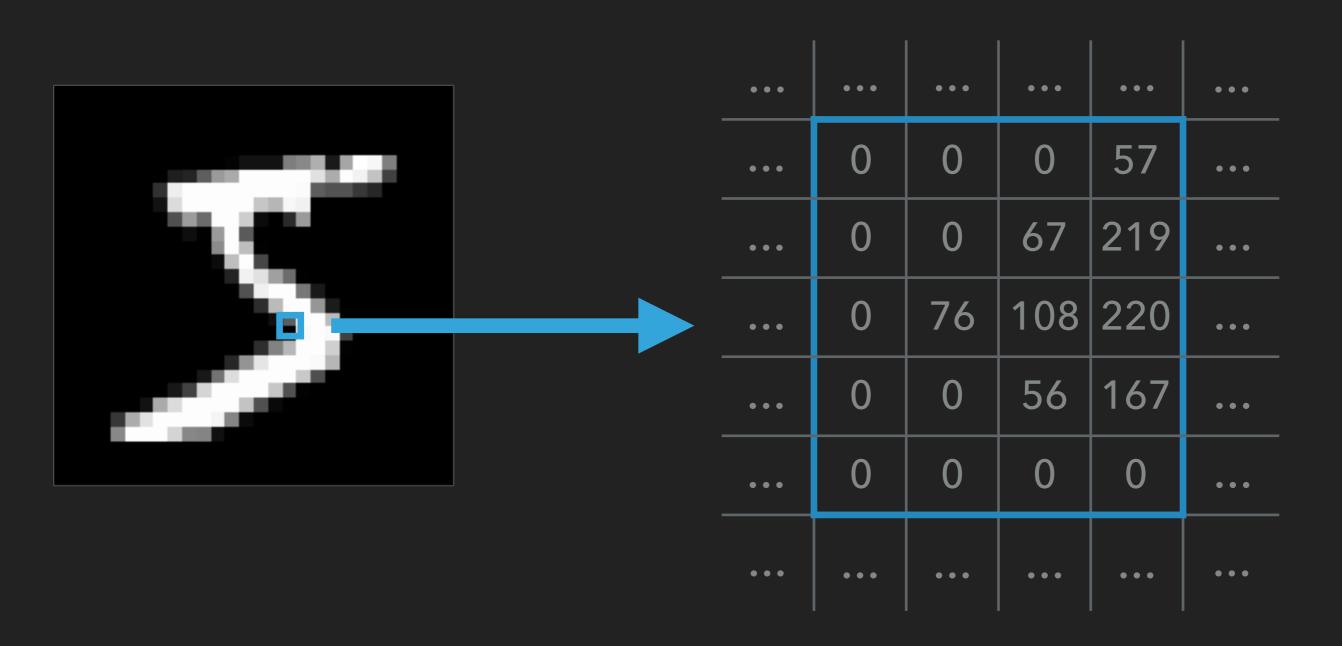
RECONNAISSANCE D'ECRITURE MANUSCRITE

- I. SPECIFICATION DU PROBLEME
- ▶ II. UN MODELE SIMPLE
- ▶ III. WRAP-UP I
- IV. REDUCTION DE LA DIMENSION
- V. WRAP-UP II



MNIST DATASET: 70 000 PHOTOS DE 28 X 28 (=784) PIXELS

L'IMAGE DEVIENT UN TABLEAU DE 784 VALEURS ENTRE 0 ET 255



LE TABLEAU DE VALEURS DEVIENT UNE LISTE (=UN VECTEUR)

				I _				
•••	•••	•••	•••	•••	•••			
• • •	0	0	0	57	•••			
•••	0	0	67	219	•••			
•••	0	76	108	220	•••		[, 0, 0, 0, 5] 0, 0, 67, 219,	[, 0, 0, 0, 57]
•••	0	0	56	167	•••			U, U, O/, Z19,.
•••	0	0	0	0	•••			
•••	•••	•••	•••	•••	•••			

ON CREE UN DATASET AVEC UN VECTEUR POUR CHAQUE IMAGE

Chiffre	Pixel 1x1	•••	Pixel 17x19	•••	Pixel 28x28
1	0	•••	219	•••	115
8	0	•••	220	•••	12
4	0	•••	167	•••	242
•••	•••	•••	•••	•••	•••

Comment déterminer le chiffre sur une photo avec seulement la donnée des valeurs des pixels?

C'est un problème de classification supervisée!

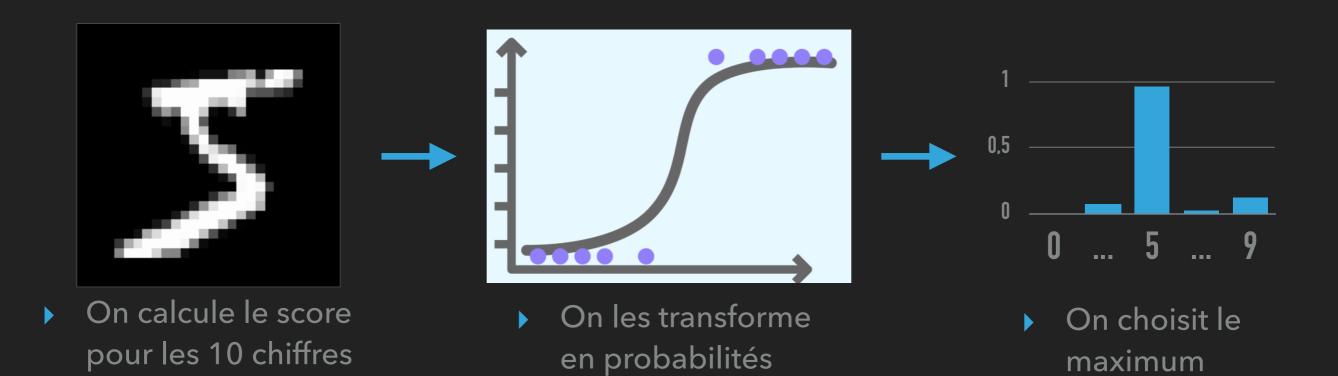
On veut bâtir un calcul qui permet de répondre

PRINCIPE DE LA REGRESSION LOGISTIQUE

Pixel	1x1	•••	17x19	•••	28x28
Chiffre 5	0	•••	219	•••	115
Poids pour 1	0.1	•••	0.32	•••	0.78
Calcul intermédiaire	0 x 0.1	x	219 x 0.32	0 x 0.1	115 x 0.78

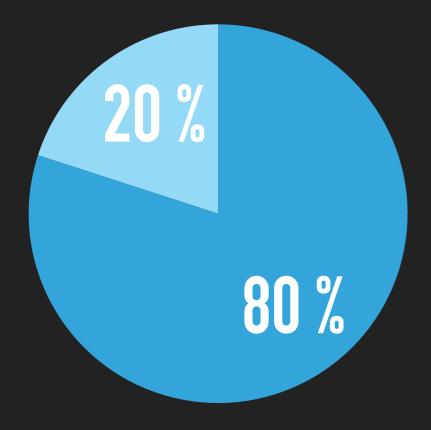
Score: est-ce un 1?

Somme des valeurs ci-dessus

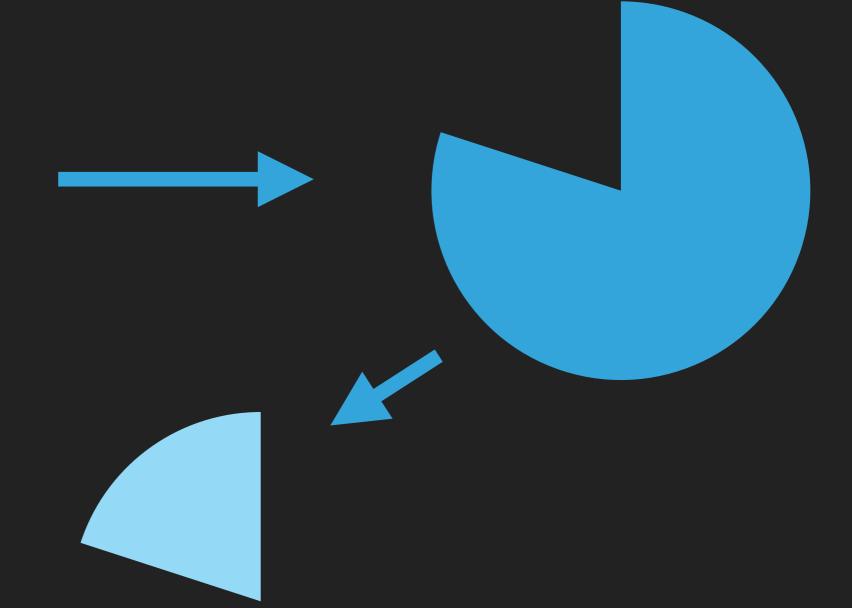


ENTRAINEMENT ET EVALUATION

Entraîner l'algorithme (=déterminer les 7840 poids)

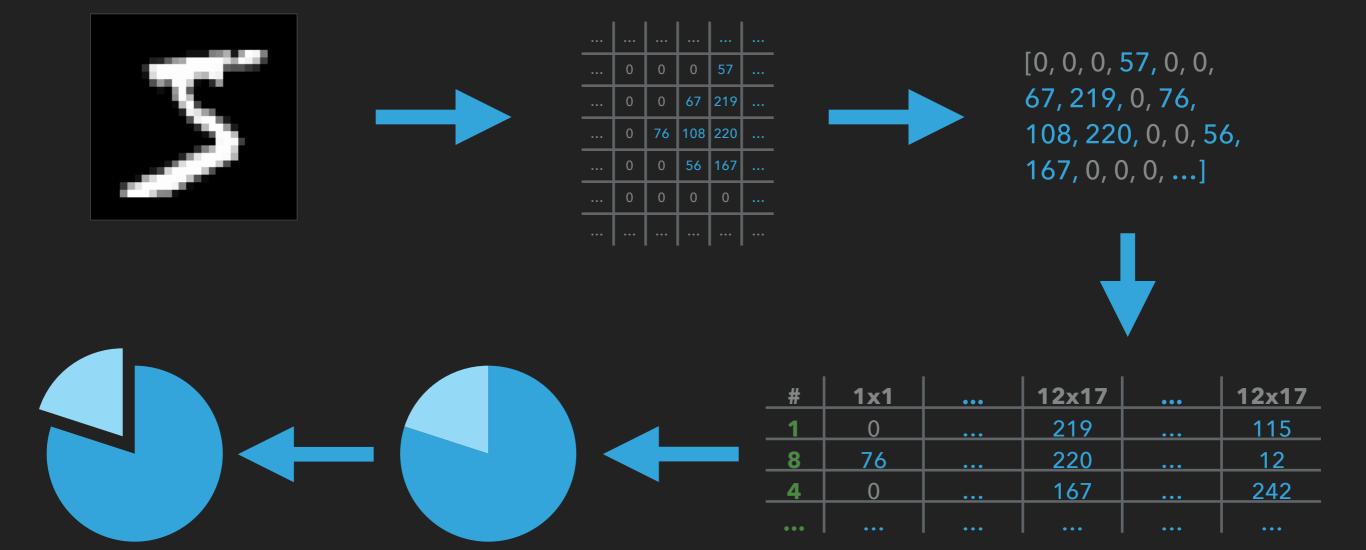


- ▶ 80 % pour entraîner
- 20 % pour tester

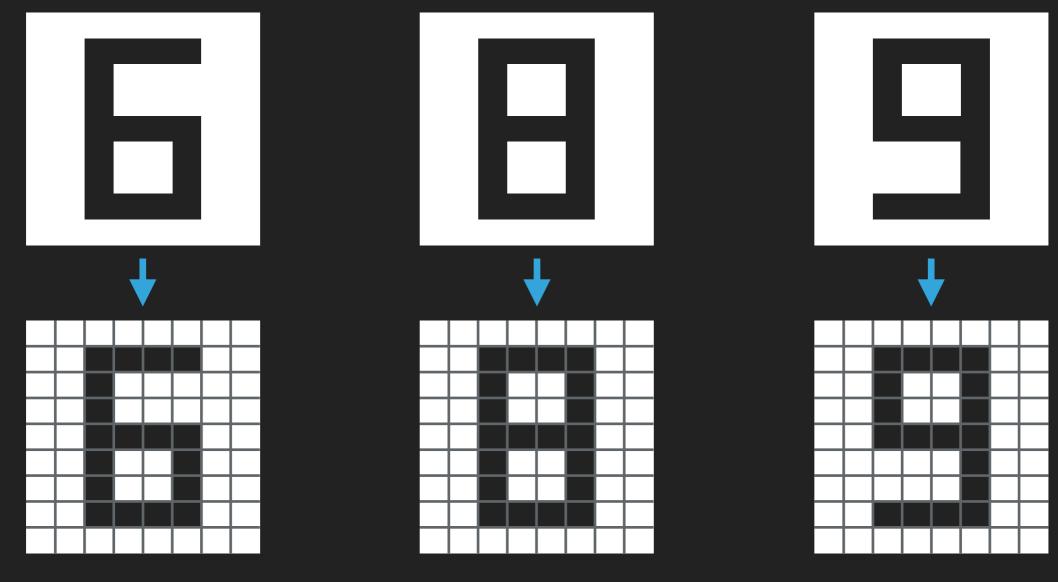


Mesurer le pourcentage de bonnes prédictions : 91,84 %

RÉSUMÉ DE NOTRE DÉMARCHE

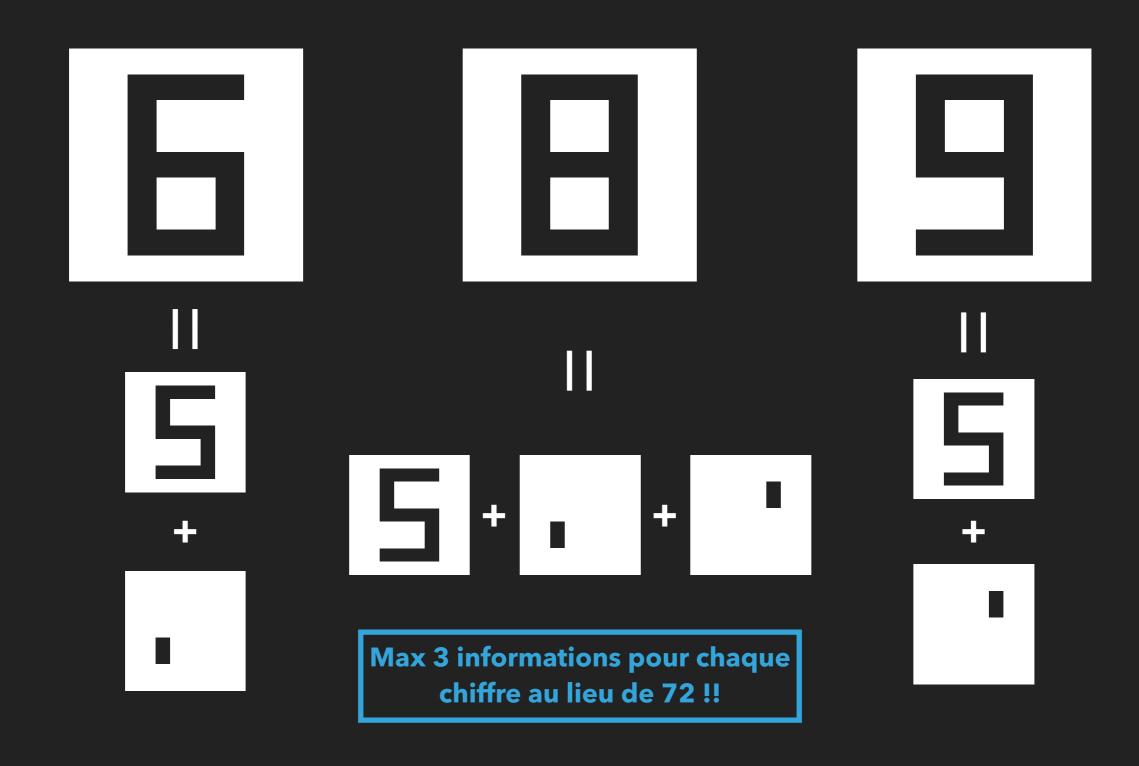


PRINCIPE DE LA REDUCTION DE DIMENSION



Le vecteur pour chaque image a 72 valeurs (=7x8) On peut essayer de réduire le nombre de dimensions

PRINCIPE DE L'ACP (ANALYSE EN COMPOSANTES PRINCIPALES)

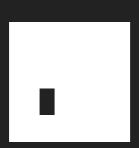


DETERMINATION DES COMPOSANTES PRINCIPALES

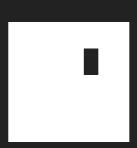


Chiffre	Pixel 1x1	•••	Pixel 17x19	•••	Pixel 28x28
1	0	•••	219	•••	115
8	0	•••	220	•••	12
4	0		167		242
•••					

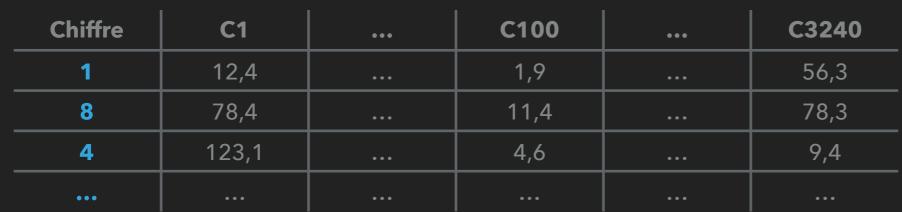
784 informations par chiffre







Analyse en	
composantes	
principales	



324 informations par chiffre

EFFETS DE LA REDUCTION DE DIMENSION

Modèle	Modèle sans ACP	Modèle après ACP	
#poids à calculer	784	324	
%bonnes prédictions	91,84 %	92,04 %	
Temps d'entraînement	16,74 s	7,28 s	

- Gains en :
 - Simplicité et explicabilité
 - Métrique de prédiction
 - Temps de calcul

MERCI POUR VOTRE ATTENTION!